5833662023 ศุภพัฒน์ นิรัตติวงศกรณ์

การตอบกลับข้อความอัตโนมัติด้วยสติกเกอร์

ที่มาและความสำคัญ

เนื่องจากปัจจุบันมีการใช้การสื่อสารผ่านโซเชียลมีเดีย(แชท) กันอย่างแพร่หลาย ซึ่งในปัจจุบันแทบทุกโซเชียลมีเดีย มีการใช้ฟังก์ชันสติกเกอร์กันเกือบทุกโซเชียลมีเดีย การตอบด้วยสติกเกอร์จึงเป็นที่นิยมของผู้ใช้งาน เนื่องจากง่าย เร็ว และบางครั้งสื่อความหมายได้ดีกว่าการพิมพ์ด้วยข้อความ

โดยโปรเจคนี้ได้ทำการนำข้อความจากการที่ผู้ใช้พิมพ์เข้ามาจากการแชท มาทำการแบ่งกลุ่มโดยใช้ machine learning แบบ unsupervised data เพื่อตอบคำถามให้แก่ผู้ใช้โดยอัตโนมัติ

วิธีการดำเนินงาน

- ข้อมูลที่ใช้: นำข้อมูลการแชทมาจากแอพพลิเคชั่น Line และ Facebook (ประวัติการสนทนา) โดยใช้ฟังก์ชันดาวน์โหลดข้อความบนแอพพลิเคชั่นนั้น ๆ กรณีดาวน์โหลดจาก Line PC จะได้เป็นไฟล์ .txt และ กรณีโหลดจาก Facebook จะเป็นไฟล์ .json
- การดำเนินงานแบ่งเป็น 3 ส่วน
    1. การจัดการกับข้อมูล (ไฟล์ cleandata.py) เป็นการนำข้อมูลที่ได้จากแอพพลิเคชั่นมาสร้างเป็น sparse feature dict โดยใช้คำและ sentiment เป็น feature (ตอนแรกลองใช้ความยาวของข้อความและจำนวนคำร่วมด้วย แต่พบว่ามีผลมากเกินไป จึงไม่ได้นำมาพิจารณา) มีการใช้ package ดังนี้
        - re (regular expression) เพื่อขูดข้อมูลจาก Line
        - os เพื่อใช้ในการเปิดไฟล์ที่อยู่ต่าง folder กัน
        - pythainlp เพื่อใช้ในการตัดคำและ sentiment analysis จากข้อความ
    2. การสร้างโมเดลการ cluster ข้อมูลโดยใช้ KMeans จากแพ็คเกจของ sklearn (ไฟล์ make_model.py) โดยใช้ข้อมูลจากการจัดการในส่วนที่ 1 หลังจากนั้นใช้ pickle เพื่อ dump โมเดลไว้ใช้งาน
    3. การใช้งานโมเดลที่สร้างขึ้น (ไฟล์ display.py) นำโมเดลที่สร้างขึ้นมาใช้งาน โดยดูกลุ่มที่แบ่งได้ ทดสอบกับข้อความที่ลองพิมพ์ขึ้นว่าอยู่ในกลุ่มใด มีการหา top feature เพื่อนำมา label กลุ่มที่ได้ ว่าควร reply ด้วยสติกเกอร์ใด

ผลการดำเนินงาน

โปรแกรมที่ได้สามารถแบ่งกลุ่มจากการพิมพ์ข้อความลงไป เพื่อการตอบกลับด้วยสติกเกอร์ได้ แต่ค่อนข้างเป็นโมเดลที่มีประสิทธิภาพไม่ดีเท่าไร (ไม่ได้ทำการประเมินค่าประสิทธิภาพต่าง ๆ เนื่องจากการ reply ด้วยสติกเกอร์อาจไม่ถูกไม่ผิด) บางครั้งโมเดลมักทายลงไปในกลุ่มเดียวกัน ทั้งที่ข้อความไม่ได้ออกไปทางเดียวกัน จากการทดลอง predict กลับด้วย training data พบว่ามีการจำแนกกลุ่มได้มากกว่า จึงคิดว่าโมเดลอาจมีการ fit กับข้อมูลมากเกินไป

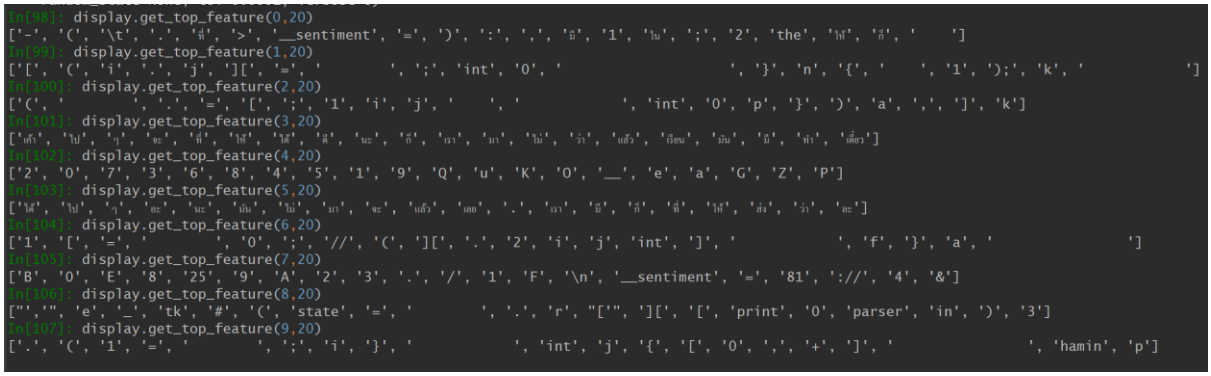

ปัญหาอาจเกิดจากตัวสมการของโมเดลที่ใช้ไม่เหมาะกับประเภทของข้อมูลหรือข้อมูลที่นำไปเทรนไม่ได้มีการจัดการที่ดีพอ สังเกตได้จากเมื่อแสดงผล top feature มักสัญลักษณ์แปลก ๆ มากกว่าคำ หรืออาจจากการที่ดาวน์โหลดมาจากแชทส่วนตัว บางครั้งมีการคัดลอกข้อความหรือ code โปรแกรมมาแปะ เพื่อส่งกันในแชท ทำให้ไม่ใช่ข้อความที่มนุษย์พิมพ์กันในชีวิตประจำวันจริง ๆ หรือ fit จากการคุยงานมากเกินไป

อุปสรรค

- การ clean data:

  06:59 Anan Sojipan รูปนี้ที่ Tokyo ครับ

  07:04 Anan Sojipan Lake okutama

  07:04 'หนึ่ง.. 👆✌🤙 ปีนี้หรือปีก่อนครับ สวยจัง

  07:05 'หนึ่ง.. 👆✌🤙 เห็นผ่านๆว่าปีนี้บางที่เริ่มเหลืองแล้วด้วย

  จากภาพจะเป็นข้อมูลที่ดาวน์โหลดมาจากไลน์ จะยากต่อการขูดข้อมูลออกมา จะสังเกตได้ว่า บางคนมีการตั้งชื่อไลน์ที่เว้นวรรคด้วย space จะไม่สามารถขูดข้อความออกมาโดยไม่มีชื่อติดมาได้
- การดาวน์โหลดข้อมูลจาก Line: การกดดาวน์โหลดจาก Line PC นั้นแต่ละครั้งจะโหลดเฉพาะข้อมูลที่แสดงในหน้าที่เราเปิดอยู่เท่านั้น และความยาวจำกัด (โดยเฉลี่ยอยู่ที่ 5 วันต่อครั้งการดาวน์โหลด) ทำให้ต้องดาวน์โหลดหลายครั้งและเสี่ยงต่อการซ้อนทับของข้อมูล
- การดาวน์โหลดข้อมูลจาก Facebook: ผู้จัดทำมาทราบช่วงหลัง ๆ ของการทำโปรเจคว่าสามารถดาวน์โหลดแชทออกมาได้เป็น .json แต่การดาวน์โหลดจาก Facebook นั้นจะต้องดาวน์โหลดมาทั้งรูปภาพ วีดีโอ และไฟล์ โดยเมื่อกด request การดาวน์โหลดแล้วทาง Facebook จะใช้เวลาประมวลผลประมาณ 1-2 วันถึงจะสามารถดาวน์โหลดได้
- การตัดคำภาษาไทยและการ sentiment analysis ใช้เวลาในการรันโปรแกรมนาน ทำให้ไม่สามารถสร้างข้อมูลจากที่ดาวน์โหลดลงมาทั้งหมดได้ จึงเลือกใช้ 100,000 ข้อความ
- การไม่ทราบเครื่องมือที่เหมาะสมกับการใช้งานจริง ๆ อาจทำให้เลือกเครื่องมือได้ไม่ดีพอ ทำให้โมเดลไม่ดีเท่าที่ควร และผู้จัดทำมีประสบการณ์กับการทำ machine learning น้อย ทำให้อาจไม่ทราบการปรับค่าบางอย่างที่ช่วยให้ผลดีขึ้น

สรุปผล

มองว่าตัวโปรเจคที่ได้ผลถ้ามองในเรื่องการใช้งานยังไม่ดีเท่าที่ควร แต่ได้ประโยชน์จากการเรียนรู้การใช้เครื่องมือต่าง ๆ เช่น การตัดคำภาษาไทย การ cluster จาก unsupervised data เป็นต้น ได้นำความรู้และทักษะการเขียนโปรแกรมภาษาไพธอน และการทำ NLP เบื้องต้นมาวิเคราะห์ออกแบบการทำงานว่าควรจัดการอย่างไรให้สามารถวิเคราะห์ข้อมูลที่เป็น string ออกมาได้ มองเห็นแนวทางในการประมวลผลข้อความมากยิ่งขึ้น